

## Metoda programării dinamice

- **Problemă.** Se consideră vectorul  $w = (w_1, \dots, w_n)$ . Să se determine un subvector al lui  $w$  care nu conține elemente consecutive în  $w$  și are suma elementelor maximă

**Exemplu:** Pentru  $w = (1, 4, 7, 5)$  soluția este  $(4, 5)$

**Problemă echivalentă:** Se consideră un graf de tip **lanț** cu  $V = \{v_1, \dots, v_n\}$ .

Vârfurile grafului au asociate ponderile  $w_1, \dots$ , respectiv  $w_n$ . Să se determine o mulțime independentă de vârfuri de pondere maximă - **Maximum Weighted Independent Set** (Aplicații – probleme de alocare de resurse cu evitarea interferenței, indicată prin muchii  $\Rightarrow$  graf de conflicte)

- **Abordare cu metoda Greedy** nu furnizează soluție optimă
  - **Abordare cu metoda Divide et Impera** - soluția nu este corectă
  - Generarea tuturor soluțiilor posibile și determinarea celei optime – algoritm exponențial
- Analizăm structura unei soluții optime, evidențiind un element (primul/ultimul) al acesteia, pentru a determina subprobleme utile și relații de recurență

Fie  $S \subseteq V = \{v_1, \dots, v_n\}$  o soluție optimă

- Dacă  $v_n \in S \Rightarrow S - \{v_n\}$  este soluție optimă pentru  $G - \{v_n, v_{n-1}\}$
- Dacă  $v_n \notin S \Rightarrow S$  este soluție optimă pentru  $G - \{v_n\}$

**Dacă am ști deja soluțiile pentru grafurile  $G - \{v_n, v_{n-1}\}$  și  $G - \{v_n\}$ , am putea determina  $S$  alegând dintre cele două situații cazul în care se obține soluția optimă**

Notăm

$S(i)$  = ponderea maximă a unei mulțimi independente în graful indus de vârfurile  $\{v_1, \dots, v_i\}$

$$S(n) = \max\{S(n-2) + w_n, S(n-1)\}$$

$$S(1) = w_1, S(0) = 0$$

- Implementăm recursiv relațiile de recurență – trebuie să memorăm într-un vector rezultatele subproblemelor deja rezolvate (memoizare), altfel aceeași subproblemă va fi rezolvată de mai multe ori  $\Rightarrow$  algoritm  $O(n)$
- sau


- Implementăm iterativ recurența (bottom-up)

Din relația de recurență putem deduce ce vârfuri au fost selectate în soluție.

**Implementare:** [MIS.java](#)

### Concluzii.

1. Metoda Divide et Impera nu este eficientă dacă subproblemele în care se împarte o problemă nu sunt distincte/ se repetă (exemplu- Fibonacci  $F(n) = F(n-1) + F(n-2)$ )



2. Prin metoda Greedy nu obținem mereu o soluție optimă (exemplu - problema rucsacului cazul discret, problema monedelor)

### • Metoda programării dinamice

Se poate aplica pentru probleme care presupun rezolvarea de relații de recurență. De obicei aceste relații se obțin din respectarea unui principiu de optimalitate (subprobleme optime)

#### Cadru general

Fie  $A$  și  $B$  două mulțimi oarecare ( $B$  este de obicei  $\mathbf{N}$ ,  $\mathbf{Z}$ ,  $\mathbf{R}$ ,  $\{0, 1\}$  sau un produs cartezian).

Fiecărui element  $x \in A$  **urmează să i se asocieze** o valoare  $v(x) \in B$ .

Inițial  $v$  este cunoscută doar pe submulțimea  $X \subset A$ ,  $X \neq \emptyset$ .

Pentru fiecare  $x \in A \setminus X$  știm că:

$$v(x) = f_x(v(a_1), \dots, v(a_k))$$

unde  $A_x = \{a_1, \dots, a_k\} \subset A$  este mulțimea elementelor din  $A$  de a căror valoare depinde  $v(x)$ , iar  $f_x$  este o funcție care specifică această dependență (poate fi un minim/maxim, o sumă etc).

Se mai dă  $z \in A$ .

Se cere să se calculeze (eficient), **dacă este posibil**, valoarea  $v(z)$ .

Lucrurile devin mai clare dacă reprezentăm problema pe un *graf de dependențe*. Vârfurile corespund elementelor din  $A$ , iar descendenții unui vârf  $x$  sunt vârfurile din  $A_x$ . Vârfurile din  $X$  apar subliniate.

#### **Exemple.**

1. Fibonacci

2. Considerăm:  $A = \{1, 2, \dots, 5, 6\}$ ;

$$v(1) = v(2) = 1$$

$$v(3) = v(1) + v(2) + v(4)$$

$$v(4) = v(1) + v(2)$$

$$v(5) = v(2) + v(3)$$

$$v(6) = v(1) + v(3) + v(4)$$

Atunci  $X = \{1, 2\}$ ;  $A_3 = \{1, 2, 4\}$ ;  $A_4 = \{1, 2\}$ ;  $A_5 = \{2, 3\}$ ;  $A_6 = \{1, 3, 4\}$ .


Fiecare funcție  $f_x$  calculează  $v(x)$  ca fiind suma valorilor elementelor din  $A_x$ . Alegem  $z=6$ . O ordine posibilă de a considera elementele lui  $A \setminus X$  astfel încât să putem calcula valoarea asociată lor este: 4, 3, 6. Astfel:

$$v(4) = v(1) + v(2) = 2,$$

$$v(3) = v(4) + v(1) + v(2) = 4,$$


$$v(6) = v(1) + v(3) + v(4) = 1 + 4 + 2 = 7$$

Să observăm că dacă dorim să calculăm  $v(6)$  este inutil să calculăm  $v(5)$ .



Ne interesează doar valorile vârfurilor  $y$  de a căror valoare depinde  $v(z)$  (adică mulțimea vârfurilor  $y$  pentru care există un drum de la  $y$  la  $z$  în graful de dependențe), numite *vârfurilor observabile* din  $z$ .

Problema enunțată nu are totdeauna soluție, așa cum se vede pe graful de dependențe de mai jos, în care există un circuit care nu permite calculul lui  $v$  în  $z=3$ .



Ar fi bine dacă, atunci când vrem să calculăm  $v(z)$  :

- am cunoaște de la început graful indus de mulțimea vârfurilor *observabile* din  $z$  ; vom numi acest graf *graful vârfurilor observabile* din  $z$  și îl notăm  $G_z$
- forma acestui graf ar permite o parcurgere mai simplă, care să conducă la calcularea valorii  $v(z)$ .

Problema enunțată **are soluție dacă și numai dacă**:

- 1)  $G_z$  nu are circuite;
- 2) vârfurile din  $G_z$  în care nu sosesc arce fac parte din  $X$ .

➤ **Încercare de rezolvare cu metoda Divide et Impera.**

Este folosită o procedură  $\text{DivImp}$ , apelată prin  $\text{DivImp}(z)$ .

```

procedure DivImp(x)
  if  $x \in X$  then  $v(x)$  este cunoscut
  else
    for toți  $y \in A_x \setminus X$  {valorile  $y$  de care  $x$  depinde direct}
      DivImp(y)
    calculează  $v(x)$  conform funcției  $f_x$ 
end;
```

Dezavantaje:

- algoritmul nu se termină pentru grafuri ciclice;
- **valoarea unui vârf poate fi calculată de mai multe ori**

➤ **Soluție: Sortarea topologică pentru  $G_z$**  (care va da ordinea în care se calculează valorile  $v$  ale vârfurilor)

Ar fi totuși mai bine dacă **forma grafului ar permite o parcurgere mai simplă.**

**Metoda programării dinamice** se aplică problemelor care urmăresc calcularea unei valori  $v(z)$  și constă în următoarele:

- 1) Se asociază problemei un graf de dependențe;
- 2) În graf este pus în evidență un graf de vârfuri observabile din  $z$  (numit **PD-arbore de rădăcină  $z$** ); acest graf are proprietățile:
  - nu conține cicluri
  - mulțimea vârfurilor cu gradul intern 0 (i.e. ale căror valori nu depind de nicio altă valoare) este inclusă în mulțimea  $X$

- se poate așeza pe niveluri (nivelul lui  $y$  = lungimea maximă a unui drum de la  $y$  la  $z$ )  
Problema se reduce la determinarea valorii asociate lui  $z$  (rădăcina PD-arborelui);

3) Se parcurge în postordine PD-arborele (cu mici modificări, marcând vârfurile vizitate, adică cele pentru care s-a calculat deja valoarea atașată, pentru a nu calcula o valoare de două ori). Mai exact, este inițializat vectorul `vizitat` și se începe parcurgerea prin apelul `postord(z)`:

```
for toate vârfurile  $x \in A$ 
    if  $x \in X$ 
        vizitat[x]  $\leftarrow$  true
    else
        vizitat[x]  $\leftarrow$  false
postord(z)
unde procedura postord cu argumentul  $x$  calculează  $v(x)$ :
procedure postord(x)
    for toți  $j \in A_x$ 
        if vizitat[j]=false    {diferența față de Divide et Impera}
            postord(j)
    calculează  $v(x)$  conform funcției  $f_x$ ;
    vizitat[x]  $\leftarrow$  true
end
```

Timpul de executare a algoritmului este evident liniar.

**Prin parcurgerea în postordine, vârfurile vor fi sortate topologic.**

Mai pe scurt, putem afirma că: **Metoda programării dinamice constă în identificarea unui PD-arbore și parcurgerea sa în postordine.**

**Observație.** Programarea dinamică generalizează metoda Divide et Impera în sensul că dependențele nu au forma unui arbore, ci a unui PD-arbore.

În multe probleme este util să căutăm în PD-arbore regularități care să evite memorarea valorilor tuturor vârfurilor și/sau să simplifice parcurgerea în postordine.

Un tip de probleme pentru care se poate utiliza metoda programării dinamice sunt **problemele de optim**, în care soluția este rezultatul unui șir finit de decizii  $d_1, \dots, d_n$  (fiecare decizie depinzând de cele anterioare), care satisfac un **principiu de optimalitate** (din care se obțin relațiile de calcul) sub una din următoarele forme. Fie secvența de stări  $S_0$  (starea inițială),  $S_1, \dots, S_n$  (starea finală) prin care se ajunge după fiecare decizie:

$$S_0 \xrightarrow{d_1} S_1 \xrightarrow{d_2} S_2 \xrightarrow{d_3} \dots \xrightarrow{d_n} S_n$$

- (1) Dacă șirul  $d_1, \dots, d_n$  duce sistemul în mod optim din  $S_0$  în  $S_n$ , atunci pentru orice  $1 \leq k \leq n$ , șirul  $d_k, \dots, d_n$  duce sistemul în mod optim din  $S_{k-1}$  în  $S_n$ .

$$(1) \quad S_0 \xrightarrow{d_1, d_2, \dots, d_n} S_n \Rightarrow S_{k-1} \xrightarrow{d_k, \dots, d_n} S_n, \quad \forall 1 \leq k \leq n$$

- (2) Dacă șirul  $d_1, \dots, d_n$  duce sistemul în mod optim din  $S_0$  în  $S_n$ , atunci pentru orice  $1 \leq k \leq n$ , șirul  $d_1, \dots, d_k$  duce sistemul în mod optim din  $S_0$  în  $S_k$

$$(2) \quad S_0 \xrightarrow{d_1, d_2, \dots, d_n} S_n \Rightarrow S_0 \xrightarrow{d_1, \dots, d_k} S_k, \quad \forall 1 \leq k \leq n$$

- (3) Dacă șirul  $d_1, \dots, d_n$  duce sistemul în mod optim din  $S_0$  în  $S_n$ , atunci pentru orice  $1 \leq k \leq n$ , șirul  $d_1, \dots, d_k$  duce sistemul în mod optim din  $S_0$  în  $S_k$ , iar șirul  $d_{k+1}, \dots, d_n$  duce sistemul în mod optim din  $S_k$  în  $S_n$

$$(3) \quad S_0 \xrightarrow{d_1, d_2, \dots, d_n} S_n \Rightarrow S_0 \xrightarrow{d_1, \dots, d_k} S_k, \forall 1 \leq k \leq n$$

$$S_{k-1} \xrightarrow{d_k, \dots, d_n} S_n, \forall 1 \leq k \leq n$$

După ce principiul optimalității a fost verificat, **se scriu relațiile de recurență corespunzătoare** (în care  $d_i$  se exprimă în funcție de  $d_{i+1}, \dots, d_n$  sau  $d_1, \dots, d_{i-1}$ , după forma în care a fost verificat principiul de optimalitate).

### • Exemplul 1. Șirul lui Fibonacci

Știm că acest șir este definit astfel:

$$F_0=0; \quad F_1=1; \quad F_n = F_{n-1} + F_{n-2}, \quad \forall n \geq 2$$

Dorim să calculăm  $F_n$  pentru un  $n$  oarecare.


Aici  $A=\{0, \dots, n\}$ ,  $X=\{0, 1\}$ ,  $B=\mathbf{N}$ , iar

$$A_k=\{k-1, k-2\}, \quad \forall k \geq 2$$

$$v(k)=F_k; \quad f_k(a, b)=a+b, \quad \forall k \geq 2$$

$$\text{Avem deci } v(k) = v(k-1) + v(k-2)$$

Un prim graf de dependențe este următorul:



Să observăm că o mai bună alegere a mulțimii  $B$  simplifică structura PD-arborelui.

$$A=\{1, 2, \dots, n\}; \quad B=\mathbf{N} \times \mathbf{N};$$

$$v(k)=(F_{k-1}, F_k); \quad f_k(a, b)=(b, a+b)$$

$$v(1)=(0, 1).$$

$$\text{Avem atunci } A_k=\{k-1\}, \quad \forall k \geq 2 \quad \text{și } v(k)=f_k(v(k-1))$$



și obținem algoritmul binecunoscut:

```

a ← 0; b ← 1
for i = 2, n
    (a, b) ← (b, a+b)
write(b)

```

### • Exemplul 2. Determinarea subșirului crescător de lungime maximă (Longest Increasing Subsequence)

Se consideră vectorul  $a=(a_1, \dots, a_n)$ . Se cere să se determine lungimea celui mai lung subșir crescător și un astfel de subșir (crescător de lungime maximă)

**Exemplu.** Pentru  $a = (8, 1, 7, 4, 6, 5, 11)$  lungimea maximă este **4**, un subșir fiind **1, 4, 6, 11**

– Înrudită cu problema determinării celui mai lung subșir comun a două șiruri (Longest Common Subsequence)

- **Aplicații:** cautarea de tiparuri (patterns): baze de date mari, bioinformatică -similitudini în genetică (ADN), alinierea secvențelor (sequence alignment)

Lavanya, B., Murugan, A.: *Discovery of longest increasing subsequences and its variants using DNA operations*. International Journal of Engineering and Technology 5(2), 1169-1177 (2013)

### Varianta 1.

**Observație (principiu de optimalitate):** Dacă  $a_{i1}, a_{i2}, \dots, a_{ip}$ , este un subșir optim (crescător de lungime maximă) care începe pe poziția  $i1$ , atunci  $a_{ik}, \dots, a_{ip}$  este un subșir optim care începe pe poziția  $ik$ .

**Subproblemă.** Calculăm pentru fiecare poziție  $i$  lungimea maximă a subșirului crescător ce **începe** pe poziția  $i$  (cu elementul  $a_i$ )

Introducem notațiile:

$nr$  = lungimea maximă căutată;

$lung[i]$  = lungimea maximă a subșirului crescător ce începe pe poziția  $i$  (cu  $a_i$ )

Atunci  $nr = \max\{lung[i] \mid i=1, 2, \dots, n\}$

**Știm direct:**  $lung[n] = 1$ .

**Are loc relația de recurență (formula de calcul):**

$$lung[i] = 1 + \max\{lung[j] \mid j > i, a_i < a_j\}$$

**Convenție:**  $\max \emptyset = 0$

Avem atunci o problemă de tipul celei generale, prezentate la începutul cursului:

$A = \{1, 2, \dots, n\}; \quad X = \{n\};$

$A_i = \{i+1, \dots, n\}$  și  $f_i = lung[i], \forall i < n;$

Evident, suntem în prezența unui PD-arbore de rădăcină 1.

**Ordinea de parcurgere a grafului de dependențe (ordinea de calcul):**

$i = n, n-1, \dots, 1$ .

Pentru a determina și **un subșir optim** (!doar un subșir), memorăm în plus

$succ[i]$  = indicele următorului element dintr-un subșir optim care începe pe poziția  $i$

**Exemplu** pas cu pas - v. slideuri

**Implementare Java** – [SubsirCrescator.java](#) (pentru o înțelegere mai ușoară vectorul are primul element pe poziția 1)

**Complexitate  $O(n^2)$**

**Observații.**

1. Determinarea tuturor subșirurilor crescătoare de lungime maximă se face printr-un backtracking (vom reveni)
2. Există o implementare  $O(n \log n)$  a acestei probleme

**Varianta 2:** Calculăm pentru fiecare poziție  $i$  lungimea maximă a subșirului crescător ce **se termină** pe poziția  $i$ .

Soluția este similară celei pentru varianta 1. PD-arborele va avea rădăcina  $n$ , iar ordinea de parcurgere va fi :  $i = 1, 2, \dots, n$ . Pentru a **memora o soluție se va folosi un vector de predecesori**:  $pred[i]$  = indicele elementului anterior lui  $i$  dintr-un subșir optim care se **termină** pe poziția  $i$

**Exemplu** pas cu pas - v. slideuri

### Varianta 3 $O(n \log n)$ - Indicații

Pentru fiecare lungime  $j=1..n$  reținem

$m[j]$  = poziția celui mai mic element din șir cu proprietatea că există un subșir de lungime  $j$  care se termină cu el

- $a[m[1]] \leq a[m[2]] \leq \dots \leq a[m[n]]$
- La pasul  $i$  – căutăm binar cea mai mare lungime  $j$  cu  $a[m[j]] \leq a[i]$

**Varianta 4  $O(n \log n)$**  – v. laborator - Patience Sort (Varianta 1 - problema 3)

**Exemplu** pas cu pas - v. slideuri

#### • Exemplul 3. Triunghi

Se consideră un triunghi de numere naturale cu  $n$  linii. Să se determine cea mai mare sumă pe care o putem forma dacă ne deplasăm în triunghi și adunăm numerele din celulele de pe traseu, regulile de deplasare fiind următoarele: pornim de la numărul de pe prima linie; la un pas ne putem deplasa pe linia următoare, dedesubt sau imediat în dreapta poziției anterioare (din  $(i,j)$  putem merge doar în  $(i+1,j)$  sau  $(i+1,j+1)$ ).

**Observații.**

1. Se pot construi în total  $2^{n-1}$  astfel de trasee (pentru fiecare linie de la 2 la  $n$  avem câte două opțiuni).
2. O strategie de tip Greedy (ne deplasăm mereu în celula cu cel mai mare număr) nu este optimă. Exemplu:

```

1
6 2
1 2 10

```

**Principiu de optimalitate:** Dacă  $(i_1, j_1), (i_2, j_2), \dots, (i_n, j_n)$  este un traseu optim care începe din celula  $(i_1, j_1) = (1,1)$ , atunci subșirul  $(i_k, j_k), \dots, (i_n, j_n)$  este un traseu optim dacă pornim din celula  $(i_k, j_k)$ .

Astfel, vom calcula pentru o poziție  $(i, j)$  suma maximă pe care o putem obține dacă **pornim din celula  $(i, j)$** . Soluția va fi valoarea obținută pentru poziția  $(1, 1)$  (**!!!ideea este asemănătoare cu cea de la subșirul crescător de lungime maximă**)

Notăm  $s[i][j]$  = suma maximă pe care o putem obține dacă **pornim din celula  $(i, j)$**

**Știm direct:**  $s[n][j] = t[n][j]$ , pentru  $j=1,2,\dots,n$  (mulțimea elementelor cunoscute  $X$  este formată din elementele de pe ultima linie -  $(n, j)$ , de pe care nu ne mai putem deplasa)

**Formulele de calcul (relația de recurență):**

$$s[i][j] = t[i][j] + \max\{s[i+1][j], s[i+1][j+1]\}$$

(( $i,j$ ) depinde de  $(i+1,j)$ ,  $(i+1,j+1)$ , deci  $A_{(i,j)} = \{(i+1,j), (i+1,j+1)\}$ )

**Soluția:**  $s[1][1]$

**Ordinea de parcurgere (de calcul):** de la ultima linie către prima; fiecare linie de la prima coloană la ultima

**Reconstituirea unei soluții:** memorăm coloana pe care ne deplasăm într-o nouă matrice  $u$ , cu semnificația

$u[i][j]$  = coloana pe care ne deplasăm din celula  $(i, j)$  pe linia  $i+1$  într-un traseu optim sau reconstituim traseul folosind relația de recurență (ne deplasăm mereu în celula de pe linia următoare cu  $s$  maxim)

**Exemplu** pas cu pas - v. slideuri

**Implementare Java** – [Triunghi.java](#).

**Complexitate**  $O(n^2)$

**Varianta 2: Principiu de optimalitate:** Dacă  $(i_1, j_1), (i_2, j_2), \dots, (i_n, j_n)$  este un traseu optim care începe din celula  $(i_1, j_1) = (1, 1)$ , atunci subșirul  $(i_1, j_1), \dots, (i_k, j_k)$  este un traseu optim care începe din celula  $(i_1, j_1) = (1, 1)$  și se termina cu celula  $(i_k, j_k)$

**Subproblemă:**  $s[i][j]$  = suma maximă pe care o putem obține dacă **pornim din (1,1) și ajungem în celula (i, j)**

**Soluția:**  $\max\{s[n][j] \mid j=1, \dots, n\}$

• **Exemplul 4. Înmulțirea optimă a unui șir de matrice**

Avem de calculat produsul de matrice  $A_1 \times A_2 \times \dots \times A_n$ , unde dimensiunile matricelor sunt respectiv  $(d_1, d_2), (d_2, d_3), \dots, (d_n, d_{n+1})$ . Știind că înmulțirea matricelor este asociativă, se pune problema ordinii în care trebuie înmulțite matricele astfel încât numărul de înmulțiri elementare să fie minim.

**Presupunem că înmulțirea a două matrice se face în modul uzual**, adică produsul matricelor  $A(m, n)$  și  $B(n, p)$  necesită  $m \times n \times p$  **înmulțiri elementare**.

Pentru a pune în evidență importanța ordinii de înmulțire, să considerăm produsul de matrice  $A_1 \times A_2 \times A_3 \times A_4$  unde  $A_1(100, 1)$ ,  $A_2(1, 100)$ ,  $A_3(100, 1)$ ,  $A_4(1, 100)$ . Pentru ordinea de înmulțire  $(A_1 \times A_2) \times (A_3 \times A_4)$  sunt necesare 1.020.000 de înmulțiri elementare. În schimb, pentru ordinea de înmulțire  $(A_1 \times (A_2 \times A_3)) \times A_4$  sunt necesare doar 10.200 de înmulțiri elementare.

**Principiu de optimalitate**  $(A_1 \times \dots \times A_k) \times (A_{k+1} \times \dots \times A_j)$  optim  $\Rightarrow$

$A_1 \times \dots \times A_k$  și  $A_{k+1} \times \dots \times A_j$  optim


**Subproblemă** Fie  $\text{cost}[i][j]$  numărul minim de înmulțiri elementare pentru calculul produsului  $A_i \times \dots \times A_j$ . Punând în evidență ultima înmulțire de matrice, obținem relațiile:

$\text{cost}[i][i] = 0, \forall i=1, 2, \dots, n$

$\text{cost}[i][j] = \min \{ \text{cost}[i][k] + \text{cost}[k+1][j] + d_i \times d_{k+1} \times d_{j+1} \mid i \leq k < j \}$ .

**Valoarea cerută** este  $\text{cost}[1][n]$ .

Vârfurile grafului de dependență sunt perechile  $(i, j)$  cu  $i \leq j$ . Valoarea  $\text{cost}[i][j]$  depinde de valorile vârfurilor din stânga și de cele ale vârfurilor de dedesubt. Se observă ușor că suntem în prezența unui PD-arbore.



Din forma particulară a PD-arborelui se observă că trebuie să parcurgem matricea astfel încât valorile  $\text{cost}[i][k]$ ,  $\text{cost}[k+1][j]$  să fie calculate înainte de  $\text{cost}[i][j]$ .



**Varianta 1.** Parcurgem în ordine coloanele 2,...,n, iar pe fiecare coloană j să mergem în sus de la diagonală până la prima linie.

```
for (j=2; j<=n; j++)
    for (i=j-1; i>=1; i--) {
        calculeaza cost[i][j] dupa relatia de recurenta
        fie k valoarea pentru care se realizează minimul
        cost[j][i]=k
    }
scrie cost[1][n]
```

(am folosit partea inferior triunghiulară a matricei pentru a memora indicii pentru care se realizează minimul).

Dacă dorim să afișăm o ordine de înmulțire optimă, vom apela `sol(1,n)`, unde procedura `sol` are forma:

```
void sol(int p,int u){
    if (p==u)
        System.out.print(p);
    else { int k = cost[u][p];
        System.out.print ('(');
        sol(p,k);
        System.out.print (',');
        sol(k+1,u);
        System.out.print(')');
    }
}
```

**Varianta 2.** Parcurgem indicii în ordinea modulului diferenței ( $i - j$ ) (paralel cu diagonala principală).

```
for (dif=1; dif<=n-1; dif++)
    for (i=1; i<=n-dif; i++){
        j = i+dif
        calculeaza cost[i][j] dupa relatia de recurenta
        fie k valoarea pentru care se realizează minimul
        cost[j][i]=k
    }
scrie cost[1][n]
```

**Implementare Java – [InmultireMatr.java](#)**

**Numărul de comparații efectuate este:**

$$\sum_{j=2}^n \sum_{i=1}^{j-1} (j-i+1) = \sum_{j=2}^n \left[ j(j-1) - \frac{(j-1)(j-2)}{2} \right] = O(n^3)$$

#### • Exemplul 5. Problema discretă a rucsacului

Se consideră un rucsac de capacitate (greutate) maximă  $G$  și  $n$  obiecte caracterizate prin:

- greutatea lor (!!!numere naturale)  $g_1, \dots, g_n$ ;
- câștigurile  $v_1, \dots, v_n$  obținute la încărcarea lor în totalitate în rucsac.

Un obiect nu poate fi fracționat.

Se cere o modalitate de încărcare de obiecte în rucsac, astfel încât câștigul total să fie maxim.

**Observație:** Aplicarea metodei Greedy eșuează în acest caz. Într-adevăr, aplicarea ei pentru:  $G=5$ ,  $n=3$  și  $g=(4, 3, 2)$ ,  $v=(6, 4, 2.5)$  are ca rezultat încărcarea primului obiect; câștigul obținut este 6. Dar încărcarea ultimelor două obiecte conduce la câștigul superior 6.5.

**Principiu de optimalitate:** Fie  $O$  o soluție optimă pentru obiectele  $\{1, \dots, n\}$  și greutatea  $G$ . Avem situațiile

- dacă  $n \in O$ , atunci  $O - \{n\}$  este soluție optimă pentru obiectele  $\{1, \dots, n-1\}$  și greutatea  $G - g_n$
- dacă  $n \notin O$ , atunci  $O$  este soluție optimă pentru obiectele  $\{1, \dots, n-1\}$  și greutatea  $G$

**Subprobleme:** Notăm  $c[i][g]$  câștigul maxim pentru greutatea  $g$  și obiectele  $\{1, \dots, i\}$

Avem relațiile de recurență:

$$c[i][g] = \begin{cases} 0, & \text{daca } i = 0 \text{ sau } g = 0 \\ c[i-1][g], & \text{daca } g_i > g \\ \max\{v_i + c[i-1][g-g_i], c[i-1][g]\}, & \text{altfel} \end{cases}$$

pentru  $i = 0, \dots, n, g = 0, \dots, G$

Suntem evident în prezența unui PD-arbore cu rădăcina  $(n, G)$

**Valorile cunoscute inițial** sunt:  $X = \{(i, 0), 0 \leq i \leq n\} \cup \{(0, g) | 0 \leq g \leq G\}$

$(i, g)$  depinde de  $(i-1, g - g_i)$  și  $(i-1, g)$ , deci de perechi cu prima componentă  $i - 1$  și cealaltă componentă mai mică sau egală cu  $g$

**Soluția:**  $c[n][G]$

**Ordinea de calcul:**  $i=1, \dots, n, \quad g=1, \dots, G$

**Complexitate:**  $O(nG)$

**Afișarea obiectelor** care conduc la costul optim: din relația de recurență, ca la triunghi sau cu o matrice  $luat[i][g]$  cu valori 1 sau 0, după cum obiectul  $i$  aparține soluției optime pentru greutatea rucsacului  $g$

**Implementarea în Java** – [Rucsac.java](#)

## Alte aplicații

### • Distanțe de editare. Alinierea secvențelor (Bioinformatică)

Putem măsura similaritatea între secvențe (ADN) prin

- **Elemente comune** – cel mai lung subșir comun pentru două secvențe
- **Distanțe de editare** – numărul minim de inserări și modificări (eventual și stergeri) de caractere necesar pentru transforma prima secvență în cea de a doua (aplicații și în procese de căutare de cuvinte – sugestii de cuvinte similare)

### • Testarea apartenenței unui cuvânt la un limbaj generat de o gramatică independentă context în formă Chomsky - v. H.Georgescu – Tehnici de programare

## Alinierea secvențelor – Exemplu

Aliniere = punerea pozițiilor (caracterelor) din cele două secvențe  $a$  și  $b$  în corespondență 1 la 1, cu posibilitatea de a insera spații.

Date două secvențe, aliniem secvențele inserând în ele caracterul “ ” astfel încât secvențele să devină de aceeași lungime și penalizând pozițiile pe care diferă secvențele obținute. Scorul (penalizarea) alinierii obținute este dat de suma penalizărilor alinierilor de caractere diferite și alinierilor caracter-spațiu (scorul Needleman-Wunsch).

**Exemplu:** ADN – alfabet A,C,G,T și cuvintele AGGGCT, AGGCA

AGGGCT

AGG-CA

penalizarea totala = penalizare spatiu + penalizare pentru diferenta T/A

**Indicație:** Subproblemă  $c[i][j]$  = scorul alinierii prefixului format din primele  $i$  litere din  $a$  cu primele  $j$  litere din  $b$